基于AI的阿尔兹海默症患者协同寻回系统

系统架构设计文档（SADD）

0. 文档信息

项目	内容
文档名称	系统架构设计文档（SADD）
版本	V1.0-R3（贯通重编排版）
日期	2026-04-05
基线来源	SRS_simplify.md（V1.0）
文档定位	定义系统级架构能力、边界和约束，作为研发、测试、运维统一基线

> 本版目标：消除“补丁式拼接”，以单一主线串联业务、架构、一致性、运维与决策。

1. 文档定位与分层边界

1.1 本文回答的问题

1. 系统如何分层、分域、集成。
2. 关键链路如何保证一致性、可用性与可观测性。
3. 高并发和分布式异常下，系统如何避免级联故障。

1.2 与 LLD 的边界

- 本文保留：架构能力、职责边界、约束与验收口径。
- 本文不展开：SQL 语句、缓存键命名、算法步进、脚本实现参数。
- 具体实现细节统一下沉至 LLD 与编码规范。

1.3 全局硬约束（Hard Constraints）

编号	约束
HC-01	TASK 域是任务状态机唯一权威，AI 不得直接改写任务状态。
HC-02	核心状态变更必须通过本地事务 + Outbox 发布。
HC-03	写请求必须支持 `request_id` 幂等拦截。
HC-04	全链路必须透传 `trace_id` 并可审计回放。
HC-05	WebSocket 多节点必须采用路由化精准下发，禁止全量广播。
HC-06	通知链路不依赖外部短信能力，仅使用应用推送与站内通知。

编号	约束
HC-07	家属端必须实现 LUI（自然语言交互界面），家属可通过对话完成寻人发布、轨迹查询等核心操作。

2. 业务主线与架构目标

2.1 端到端主线

1. 家属建档并建立监护关系。
2. TASK 域发起寻回任务。
3. 路人通过匿名入口上报线索。
4. CLUE 域完成研判与时空处理，产出状态事件。
5. TASK 域收敛任务状态并触发通知。
6. AI 域输出策略建议，由 TASK 域决策采纳。
7. 任务闭环后完成轨迹归档与经验沉淀。
8. 全链路写审计并纳入可观测体系。

2.2 架构目标

- 目标 A：高并发下保持状态一致和事件可恢复。
- 目标 B：跨域协作不依赖高频同步 RPC。
- 目标 C：关键链路具备幂等、防乱序、防重放。
- 目标 D：异常可降级、故障可定位、数据可追责。

3. 总体架构

3.1 参与者与外部依赖

类型	实体	说明
业务角色	家属/监护人	建档、发起/关闭任务、查看进展、AI 对话、物资申领
业务角色	路人发现者	匿名线索上报
管理角色	普通管理员	复核、协查、工单处理、审计查询
管理角色	超级管理员	高危治理能力
外部系统	大模型服务	推理与生成
外部系统	地图定位服务	坐标与地理能力
外部系统	消息推送服务	应用推送触达（不含短信）

3.2 上下文总览（PlantUML）

```
@startuml
left to right direction

actor 家属_监护人 as Family
actor 路人发现者 as Passerby
actor 普通管理员 as Admin
actor 超级管理员 as SuperAdmin

rectangle 接入安全层 as ACCESS
rectangle 协同寻回系统 as SYS
rectangle 大模型服务 as LLM
rectangle 地图定位服务 as MAP
rectangle 消息推送服务_不含短信 as PUSH

Family --> ACCESS
Passerby --> ACCESS
Admin --> ACCESS
SuperAdmin --> ACCESS

ACCESS --> SYS
SYS --> LLM
SYS --> MAP
SYS --> PUSH
@enduml
```

3.3 分层架构

层级	核心职责	关键约束
接入安全层	路由、鉴权透传、限流、幂等拦截	轻量化，不承载复杂业务状态机
应用层	用例编排、事务边界、跨域协调	不承载核心领域规则
领域层	聚合、状态机、领域服务	状态迁移必须走聚合根
事件与集成层	Topic 解耦、Outbox 投递、Saga 协作	保证最终一致可证明
数据基础设施层	存储、缓存、消息、向量能力	选型必须与 SRS 口径一致
治理层	审计、追踪、监控、告警	全链路可观测与可追责

3.4 基础设施选型（架构层）

能力域	选型	架构要求
主数据与事务	PostgreSQL 16	支撑核心业务事务与事件发布基线
时空计算	PostGIS	提供围栏与邻近判定能力
向量检索	pgvector + HNSW	支撑 RAG 低延迟召回

能力域	选型	架构要求
事件总线	Kafka	事件削峰、解耦、重试与重放
分布式缓存	Redis + Lua	幂等、配额、路由态与热数据
通知背板	Redis Pub/Sub 或 Kafka Backplane	WebSocket 集群间消息转发
发号能力	全局序列服务 + 缓存消费层	保证短码序列唯一、单调、不回退

3.5 接入安全能力拆分

组件	主职责
Security Gateway	路由与策略执行
Authentication Service	验签、短码解码、重放校验
Risk Service	CAPTCHA 与行为风控

4. 领域架构（DDD）与职责边界

4.1 六域映射

领域	定位	核心职责
寻回任务执行域	核心域	任务生命周期、状态收敛与寻回闭环（HC-01 唯一权威）
线索与时空研判域	核心子域	线索接入、研判、围栏判定、轨迹处理
患者档案与监护域	支撑域	患者档案、监护关系管理
标签与物资运营域	支撑域	标签主数据、绑定流程、工单与物流闭环
AI 协同支持域	支撑域	AI Agent 自然语言交互、Function Calling 编排、策略建议（通过标准域 API 执行，不直接写域实体表；集成 Spring AI Alibaba）
通用治理域	通用域	身份、权限、审计、配置、Outbox 治理、通知

4.2 域间协作（PlantUML）

```
@startuml
left to right direction

package 核心域 {
  [寻回任务执行域] as TASK
```

```
}

package 核心子域 {
  [线索与时空研判域] as CLUE
}

package 支撑域 {
  [患者档案与监护域] as PROFILE
  [标签与物资运营域] as MAT
  [AI 协同支持域] as AI
}

package 通用域 {
  [通用治理域] as GOV
}

PROFILE --> TASK
PROFILE --> CLUE
CLUE --> TASK
TASK ..> CLUE : task.state.changed
TASK --> AI : 只读上下文
AI ..> TASK : «Function Calling»\ncreateRescueTask / closeTask
AI ..> CLUE : «Function Calling»\nqueryTrajectory
AI ..> TASK : ai.strategy.generated
MAT --> PROFILE : 绑定时查询授权
MAT ..> PROFILE : tag.bound

AI --> GOV
CLUE --> GOV
TASK --> GOV
MAT --> GOV
PROFILE --> GOV
@enduml
```

4.3 领域权威约束

- TASK 域是任务状态唯一权威（HC-01）。
- AI Agent 通过 Function Calling 调用各域标准 REST API 执行业务操作（如发布任务、查询轨迹），所有写操作经 Policy Guard 门禁校验后由目标域服务自身完成状态变更；AI 服务不直接写入域实体表。
- `tag_asset` 写模型归属标签与物资运营域（MAT），档案域通过事件协作。
- 跨域协作优先事件驱动，不允许跨域直接写库。
- TASK↔CLUE 双向事件接口已冻结（`task.state.changed`、`clue.validated`、`fence.breached`、`track.updated`），变更需架构评审。
- 接入安全层（gateway-security / auth-service / risk-service）为基础设施，不计入业务领域。
- 通知能力为通用治理域子能力，不构成独立领域。

4.4 线索域高并发拆分边界

```
@startuml
left to right direction

actor 路人发现者 as P
component ClueIntake as INTAKE
queue Kafka as K
component SpatialAnalysis as SA
component Trajectory as TRAJ
database PostgreSQL_PostGIS as PG

P -> INTAKE : 匿名上报
INTAKE -> K : clue.reported.raw
K -> SA : 研判与时空计算
SA -> K : clue.validated / fence.breached / track.updated
SA -> PG : 线索状态落库
TRAJ -> PG : 轨迹归档
@enduml
```

4.5 围栏抑制跨域状态下发

机制	架构约束
状态下发	TASK 迁移状态后发布 `task.state.changed`（含时序标识）
缓存层级	CLUE 采用 `L1` 本地缓存 + `L2` Redis 只读缓存
判定路径	先读 `L1`，未命中读 `L2`，禁止高频同步 RPC 拉 TASK
防乱序	基于时序标识执行条件更新，禁止旧状态覆盖新状态
降级原则	仅当 `L1/L2` 同时不可用或均未命中才进入抑制分支

5. 事件驱动与一致性架构

5.1 接口契约基线

约束项	架构要求
幂等	写请求必须支持 `request_id` 幂等拦截
追踪	响应与日志必须携带 `trace_id`
错误语义	业务错误与系统错误分层表达
防乱序	消费端必须阻止陈旧事件覆盖最新状态

补充：

- 幂等键空间与命名规范由 LLD 定义。

- 围栏判定链路必须依赖状态事件下发后的缓存态。

5.2 核心事件清单

事件	生产方	消费方	语义
`clue.reported.raw`	Clue Intake	Spatial Analysis	原始线索入站削峰，不走 Outbox
`clue.validated`	线索服务	任务服务、AI服务	有效线索进入任务与策略链路
`clue.suspected`	线索服务	管理复核服务、任务服务	可疑线索进入人工复核分支并触发治理协同
`track.updated`	线索服务	任务服务、AI服务	轨迹增量更新
`fence.breached`	线索服务	任务服务	越界告警触发
`task.state.changed`	任务服务	线索服务	下发患者状态用于围栏抑制
`task.created`	任务服务	档案、AI、通知服务	任务启动
`task.resolved`	任务服务	档案、线索、通知、AI记忆	任务确认寻回闭环
`task.false_alarm`	任务服务	档案、线索、通知	误报关闭，不沉淀经验
`ai.strategy.generated`	AI服务	任务服务	策略建议
`ai.poster.generated`	AI服务	任务服务	海报异步回写
`profile.created`	档案服务	AI向量化服务	新建档案后触发向量化初始化
`tag.bound`	物资服务	档案服务	标签绑定完成后通知档案域同步状态
`material.order.created`	物资服务	管理端处理器	物资工单创建
`clue.rejected`	管理复核服务	线索服务、任务服务	管理员驳回可疑线索
`profile.updated`	档案服务	AI 向量化服务	档案更新后触发向量重建
`profile.corrected`	档案服务	AI 向量化服务	档案勘误后触发向量重建
`profile.deleted.logical`	档案服务	AI 向量化服务	逻辑删除后清理向量
`clue.vectorize.requested`	线索入口服务	AI 向量化服务	线索文本向量化请求
`memory.appended`	AI 服务	AI 向量化服务	记忆条目新增
`memory.expired`	AI 服务	AI 向量化服务	记忆条目过期清理

5.3 Outbox 强一致投递模型

1. 状态变更与 Outbox 记录同一本地事务提交。
2. 事务提交后异步发布事件。
3. 投递失败进入重试与死信机制。
4. 消费端必须幂等并防乱序。
5. 消费端业务更新与本地幂等日志写入必须同事务提交。
6. Outbox 必须实施生命周期治理，防止表膨胀。

适用边界：

- Outbox 仅用于领域状态变更事件。
- Intake 原始事件先入 Kafka，再异步落库。

生命周期要求：

- Outbox 必须具备自动归档/清理机制。
- 清理必须错峰与限速，避免反压主库。
- DEAD 事件必须具备受控人工干预入口（诊断、修复、重放），且修复前分区闸门持续生效。
- 干预动作必须全量审计并可追溯（operator_user_id/operator_username、reason、trace_id、before_phase、after_phase）。

5.4 跨域长事务（Choreography Saga）

- 采用 Choreography，不引入中心编排器单点。
- 主链以 TASK 状态收敛为准。
- 子链路失败走补偿，不回滚主状态。

5.5 WebSocket 集群精准路由（防惊群）

```
@startuml
actor 家属用户A as U
node WS节点1 as WS1
node WS节点2 as WS2
database Redis路由表 as R
queue Kafka业务事件 as EB
queue 定向通道 as PTP

U --> WS1 : 长连接建立
WS1 -> R : user_id -> pod_id

EB -> WS2 : 消费事件
WS2 -> R : 查询目标连接节点
WS2 -> PTP : 定向投递(ws.push.{pod_id})
PTP -> WS1 : 点对点下发
WS1 --> U : 消息送达
@enduml
```

约束：

- 禁止全节点 Global Topic 无差别广播。
- 必须先路由查询再定向下发。
- 路由缺失时降级到应用推送/站内通知。
- 路由心跳续期必须采用抖动窗口与阈值续期，禁止全连接同频写路由存储。
- 路由存储短暂不可用时，必须触发可观测降级并启用推送/站内通知兜底。

6. AI 架构

6.1 AI 执行边界

1. 接收用户自然语言输入并理解意图。
2. 组装上下文（任务状态、线索轨迹、患者档案）。
3. 执行检索增强（RAG）。
4. 通过 Function Calling 调用域 API 完成业务操作（如发布任务、查询轨迹）。
5. 生成策略建议并发布事件。
6. 记录审计与可观测信息。

边界约束：

- AI Agent 通过 Spring AI Alibaba 的 `ChatClient` + `FunctionCallback` 实现 Tool-Use 编排。
- 所有 Function Calling 写操作必须经 Policy Guard 门禁校验后，由目标域服务自身完成状态变更。
- AI 服务不直接写入域实体表（`rescue_task`、`clue_record` 等），HC-01 不变。
- TASK 域仍是任务状态唯一权威；AI 的 `create_rescue_task` 调用实质是调用 `POST /api/v1/rescue/tasks`。
- 只读查询（如轨迹、快照）按 A0 等级允许 AI 自动执行，无需人工确认。

Agent 执行分级（架构级）：

等级	执行语义	架构约束
A0	自动观测	只读、聚合、预警，允许自动执行
A1	智能助理	草稿与建议，写操作必须人工确认
A2	受控执行	常规写操作可执行，要求 `CONFIRM_1`
A3	高风险执行	状态变更治理操作可执行，要求 `CONFIRM_2/3`
A4	人工专属	不可逆与合规敏感操作，`MANUAL_ONLY`

硬边界：

1. `A4` 操作永不允许 Agent 自动执行。
2. 任何 AI 触发写操作必须通过策略门禁（Policy Guard）与审计链路。

6.2 RAG 路由约束

- 必须先注入患者维度隔离，再执行向量召回。
- 必须启用数据有效性过滤（失效/过期/替代数据不得召回）。
- 误报任务不得沉淀为可召回经验。
- 具体查询语句和索引参数由 LLD 定义。

6.3 AI 双账本配额

维度	架构要求
配额账本	`user_id` 全局账本 + `patient_id` 全局账本
预占机制	原子预占并写入待确认记录
确认机制	推理完成后异步对账并确认
超时补偿	待确认超时必须自动回滚预占
崩溃恢复	网关重启后必须恢复未决配额状态

6.4 上下文窗口防护（Context Overflow Guard）

环节	架构要求
Token 预估	推理前必须完成 Token 统计与阈值校验
超限处理	超限请求必须进入确定性截断流程
可审计性	必须记录截断前后规模与策略命中路径
失败语义	触发 `L2` 类错误并发布结构化事件

硬约束：

- 严禁将超出模型上下文窗口的 Payload 直接下发模型。

6.5 AI 失败语义分级

等级	语义	处理策略
L1	物理链路失败	快速重试 + 熔断
L2	推理逻辑失败	模板降级
L3	工具链失败	降级动作 + 人工介入
L4	内容安全阻断	强阻断 + 审计

6.6 Agent 执行策略门禁（Policy Guard）

1. 入站识别：`action_source`（USER/AI_AGENT）与 `agent_profile` 必须可识别。
2. 策略校验：角色权限、数据归属、执行模式、确认等级必须全部通过。
3. 预检查：支持 `dry_run`，仅校验不落副作用。
4. 失败语义：

- 策略拒绝 -> `E_GOV_4039`
- 确认等级不足 -> `E_GOV_4097`
- 预检查失败 -> `E_GOV_4226`
- 人工专属操作被 Agent 调用 -> `E_GOV_4231`

5. 审计要求：策略命中路径与拦截原因必须可回放。

6.7 Agent 能力包与 Function Calling 架构对齐

能力包开关（`sys_config.scope=ai_policy`）必须与 API 白名单同粒度：

agent_profile	config_key
RescueCommander	`agent.capability.rescue.enabled`
ClueInvestigator	`agent.capability.clue.enabled`
GuardianCoordinator	`agent.capability.guardian.enabled`
MaterialOperator	`agent.capability.material.enabled`
AICaseCopilot	`agent.capability.ai_case.enabled`
GovernanceSentinel	`agent.capability.governance.enabled`
OutboxReliabilityAgent	`agent.capability.outbox_reliability.enabled`

Agent 策略配置键（`sys_config.scope=ai_policy`）：

config_key	说明
`agent.execution.max_level`	允许执行上限（A0/A1/A2/A3）
`agent.confirmation.policy`	确认级别策略映射
`agent.manual_only.actions`	人工专属接口白名单

说明：上述策略键与能力包开关键共同构成 `ai_policy` 作用域下的完整 Agent 治理键集。

Function Calling 的 `action` 必须命中白名单，并通过现有业务接口执行（禁止内部旁路写）：

家属侧核心操作（A0-A2，支撑自然语言完成寻人发布与轨迹查询）：

action	目标接口	执行等级	约束
`create_rescue_task`	`POST /api/v1/rescue/tasks`	A2（`CONFIRM_1`）	家属确认后执行
`query_task_snapshot`	`GET /api/v1/rescue/tasks/{task_id}/snapshot`	A0	只读，允许自动执行
`query_trajectory`	`GET /api/v1/rescue/tasks/{task_id}/trajectory/latest`	A0	只读，允许自动执行
`query_patient_profile`	`GET /api/v1/patients/{patient_id}`	A0	只读，允许自动执行
`query_clue_list`	`GET /api/v1/rescue/tasks/{task_id}/clues`	A0	只读，允许自动执行

管理与治理操作（A1-A4）：

action	目标接口	最低确认	约束
`propose_close`	`POST /api/v1/rescue/tasks/{task_id}/close`	`CONFIRM_1`	可执行
`clue_override`	`POST /api/v1/clues/{clue_id}/override`	`CONFIRM_2`	可执行
`clue_reject`	`POST /api/v1/clues/{clue_id}/reject`	`CONFIRM_2`	可执行
`approve_material_order`	`PUT /api/v1/admin/material/orders/{order_id}/approve`	`CONFIRM_2`	可执行
`archive_session`	`POST /api/v1/ai/sessions/{session_id}/archive`	`CONFIRM_1`	可执行
`replay_outbox_dead`	`POST /api/v1/admin/super/outbox/dead/{event_id}/replay`	`CONFIRM_3`	可执行
`request_evidence`	`POST /api/v1/admin/clues/{clue_id}/request-evidence`	`MANUAL_ONLY`	本版本暂不开放，仅可建议
`force_close_task`	`POST /api/v1/admin/super/rescue/tasks/{task_id}/force-close`	`MANUAL_ONLY`	A4 动作，仅人工页面可执行

执行回执要求：

1. 若 action 执行成功，必须返回 `action_id`、`result_code`、`executed_at`。
2. 上述回执字段必须通过 AI 流式 `done` 事件透传，保证端到端可观测与可审计。

7. 数据与存储架构

7.1 概念实体基线

实体	核心属性
患者档案	基本信息、走失状态
监护关系	角色与关系状态
标签资产	标签状态与绑定关系
寻回任务	生命周期状态
线索记录	时空信息、有效性与复核状态
轨迹数据	聚合结果与窗口信息
AI 会话与记忆	摘要、配额、记忆状态
审计日志	主体、动作、结果、追踪标识

7.2 时空与向量能力

- 时空能力：PostGIS + 标准坐标体系。
- 向量能力：pgvector + HNSW。
- 检索隔离：患者维度 + 数据有效性 + 版本约束。

7.3 短码能力

- 必须具备全局序列与短码映射能力。
- 必须保证主备切换后序列不回退、不重复。
- 发号必须采用“数据库序列真源 + 服务节点号段预取”模式，禁止纯随机短码。
- 节点故障后未消费号段必须可废弃，禁止回填导致短码碰撞。
- 必须定义短码发号灾备 Runbook（主备切换、水位校准、回退禁止）。
- 具体发号步长与映射算法由 LLD 定义。

7.4 Outbox 与本地幂等日志治理

对象	治理要求
Outbox	生命周期管理、防膨胀、可清理、可审计
本地幂等日志	唯一约束拦截重复消费
消费事务	业务更新与幂等日志同事务提交
DEAD 干预	仅受控重放、保留分区闸门、全量审计

7.5 删除与归档策略

- 业务对象以状态迁移为主，不做随意物理删除。
- 审计日志追加写入，按周期归档。
- 历史数据清理应满足审计留存要求。

8. 安全、合规与审计

8.1 接入安全层职责

组件	主职责
Security Gateway	路由与策略执行
Authentication Service	验签、短码解码、重放校验
Risk Service	风控评分与挑战机制

8.2 安全控制基线

- 接入层统一鉴权与反重放。
- 高危操作必须二次确认并审计。
- 业务服务只接收已验证内部标识。

8.3 审计规范

维度	要求
审计范围	身份、档案、任务、线索、物资、AI 全链路
审计字段	`operator_user_id`、`operator_username`、`object_id`、`action`、`result`、`risk_level`、`detail`、`trace_id`、`request_id`、`action_source`、`agent_profile`、`execution_mode`、`confirm_level`、`blocked_reason`、`action_id`、`result_code`、`executed_at`
完整性	可检索、可回放、可归档，覆盖率必须 100%

9. 非功能目标与运维基线

9.1 量化 SLO

指标项	目标值	口径
纯事务写链路延迟	`TP99 <= 200 ms`	状态变更与事务提交链路
含时空计算写链路延迟	`TP99 <= 600 ms`	含时空计算同步链路
线索上报吞吐	单节点峰值 `QPS >= 3000`	入站削峰后的系统口径
跨域一致性时延	`TP99 <= 3 s`	事件发布到状态收敛
告警触达时延	`TP99 <= 3 s`	WebSocket 主通道 + 降级通道
审计覆盖率	`100%`	关键动作不可缺失

9.2 部署建议

- 应用服务多副本无状态部署。
- PostgreSQL、Kafka、Redis 高可用部署。
- WebSocket 必须启用路由存储与定向下发通道。
- 安全能力组件必须独立伸缩与故障隔离。

9.3 可观测指标

维度	指标
接口层	成功率、P95/P99、错误码分布
事件层	积压、消费延迟、死信量、定向下发失败率
一致性层	Outbox 待投递量、清理负载、幂等冲突率、收敛时延
AI 层	L1-L4 占比、配额对账偏差、上下文溢出拦截率
安全层	鉴权失败、风控命中、重放拦截

9.4 演练建议

1. WebSocket 多节点定向路由演练。
2. 幂等重放风暴演练。
3. Outbox 收敛与清理错峰演练。
4. AI 上下文超限防护演练。
5. DEAD 人工干预与分区闸门恢复演练。

10. 验收映射（SRS -> SADD）

SRS 验收条目	架构落地点
闭环演示可完成	任务域 + 线索域 + AI 域 + 审计治理
路人匿名可上报	接入安全层 + Intake 削峰
无重复进行中任务	幂等拦截 + 状态机约束
存疑线索可闭环	复核分支 + 任务收敛
误报不污染经验	`task.false_alarm` 语义约束
物资自动闭环	`tag.bound` 事件驱动
关键操作可追溯	`trace_id` + 审计规范

11. 风险与演进策略

风险点	当前策略	演进方向
Outbox 膨胀拖慢主库	生命周期治理 + 错峰清理	分层存储与冷热归档
消费幂等跨存储不一致	本地幂等日志同事务提交	幂等治理 SDK 化
Intake 与 Outbox I/O 冲突	原始事件先入 Kafka	分层容量与回压治理
围栏跨域状态依赖	`task.state.changed` + L1/L2 缓存	状态快照预热与回补

风险点	当前策略	演进方向
CLUE 冷启动缓存穿透	双层缓存与冷启动保护	快照回放与自动预热
短码发号漂移风险	全局序列真源 + 缓存消费	分片号段与多活治理
WebSocket 惊群效应	路由查询 + 定向下发	分片路由与多背板容灾
DEAD 长驻阻塞分区	分区闸门 + 人工修复重放	干预自动化与审计编排
AI 上下文溢出	Token 预估 + 截断防线	上下文压缩与记忆分层
配额确认丢失	待确认超时回滚	跨日自动对账修复
物资链路遗漏	`tag.bound` 自动收敛	异常回放与人工补偿

12. 实施落地检查清单

1. 是否落实 TASK 状态权威与 AI 建议边界。
2. 是否实现 Outbox 同事务发布与重试补偿。
3. 是否实现消费端本地幂等日志同事务提交。
4. 是否实现事件防乱序覆盖能力。
5. 是否区分 Intake 原始事件与领域状态变更事件。
6. 是否落地 `task.state.changed` 状态下发与 L1/L2 缓存。
7. 是否落地短码全局序列能力并保证不回退。
8. 是否启用 AI 双账本配额与超时回滚。
9. 是否启用上下文超限阻断与确定性截断。
10. 是否完成 WebSocket 路由查询后的定向下发。
11. 是否启用 Outbox 生命周期清理并验证不反压主库。
12. 是否接入 L1-L4 失败语义监控与告警分流。
13. 是否验证 `tag.bound` 驱动物资自动闭环。
14. 是否完成多节点路由、幂等风暴、Outbox 收敛联合演练。

13. 结论

本架构已形成“主线清晰、边界明确、事件一致性可证明、运行稳定性可治理”的统一工程基线，可直接用于研发、测试、运维与答辩协同。

14. Architecture Decision Records（ADR）

14.1 ADR 索引

ADR 编号	决策主题	状态
ADR-001	为什么选择 Choreography Saga	Accepted
ADR-002	为什么 AI 不拥有状态权威	Accepted

ADR 编号	决策主题	状态
ADR-003	为什么使用 pgvector 而非外部向量数据库	Accepted
ADR-004	为什么采用 Outbox 而非 CDC-only	Accepted
ADR-005	为什么 A4 操作必须 MANUAL_ONLY	Accepted

14.2 ADR-001 为什么选择 Choreography Saga

维度	内容
背景	多域协作链路长，中心编排器易形成单点瓶颈。
决策	采用 Choreography，以事件协作实现最终一致。
影响	提升解耦与扩展性，补偿治理复杂度上升。
回看条件	当补偿分支复杂度持续上升时评估局部编排器。

14.3 ADR-002 为什么 AI 不拥有状态权威

维度	内容
背景	AI 输出非确定性，不适合承担状态机写入权。
决策	TASK 域保持状态权威，AI Agent 通过 Function Calling 调用标准域 API 触发业务操作，写入由目标域服务校验并执行。
影响	状态一致性更强；AI 具备真正的 Agent 能力（自然语言发布任务、查询轨迹），同时不破坏域权威。
回看条件	模型可验证能力显著提升后再评估授权边界。

14.4 ADR-003 为什么使用 pgvector 而非外部向量数据库

维度	内容
背景	检索与业务隔离、有效性过滤、审计链路强耦合。
决策	当前阶段采用 pgvector 同库检索。
影响	一致性与运维成本更优，超大规模弹性相对受限。
回看条件	当容量或延迟长期超 SLO 时评估混合架构。

14.5 ADR-004 为什么采用 Outbox 而非 CDC-only

维度	内容
背景	关键业务要求“状态提交与事件发布”一致性可证明。
决策	Outbox 作为发布基线，提交后异步投递。
影响	消除幽灵事件风险，增加投递与清理治理成本。
回看条件	当平台原生事务事件能力可替代时再评估。

14.6 ADR-005 为什么 A4 操作必须 MANUAL_ONLY

维度	内容
背景	超管导出、日志清理、强制闭环等操作具备不可逆或强合规属性。
决策	将该类动作定义为 `A4`，仅允许人工页面触发，Agent 仅可给建议与预检。
影响	降低自动化误操作与越权风险，增加人工确认成本。
回看条件	当法规、审计自动化能力与二人复核机制成熟后再评估。